Jurnal Riset Statistika (JRS)
e-ISSN 2798-6578 | p-ISSN 2808-3148
https://journals.unisba.ac.id/index.php/JRS

Tersedia secara online di
Unisba Press
https://publikasi.unisba.ac.id/

Penerapan *Bayesian Dynamic Linear Models* untuk Peramalan Harga Komoditas Beras Medium

Mohamad Gilang Ramdani, Nur Azizah Komara Rifai*

Prodi Statistika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Islam Bandung, Indonesia

ARTICLE INFO

Article history :
Received : 28/9/2025
Revised : 17/12/2025
Published : 29/12/2025

Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International License.

Volume : 5
No. : 2
Halaman : 161 - 170
Terbitan : **Desember 2025**

Terakreditasi Sinta Peringkat 4 berdasarkan Ristekdikti No. 177/E/KPT/2024

ABSTRAK

Harga beras medium di Indonesia memiliki peran penting dalam menjaga stabilitas ekonomi dan ketahanan pangan nasional. Fluktuasi harga yang bersifat dinamis, dipengaruhi oleh faktor musiman dan perubahan tren jangka panjang, menuntut metode peramalan yang adaptif. Penelitian ini menerapkan *Bayesian Dynamic Linear Models* (BDLM) untuk meramalkan harga beras medium menggunakan data bulanan BPS dan Bapanas periode 2014-2023. Model yang digunakan terdiri atas komponen tren polinomial orde dua dan komponen musiman harmonik dengan pendekatan *state space*, serta diperbarui secara berurutan menggunakan *Kalman filter*. Hasil penelitian menunjukkan bahwa BDLM mampu menangkap variasi tren dan musiman secara efektif dengan tingkat akurasi yang tinggi, ditunjukkan oleh nilai MAPE sebesar 4,33%. Temuan ini sejalan dengan penelitian sebelumnya yang menyatakan bahwa model dinamis bayesian memiliki kemampuan adaptif yang unggul dalam memodelkan perubahan struktural pada deret waktu ekonomi. Dengan demikian, BDLM dapat dijadikan alternatif yang tepat dalam peramalan harga komoditas pangan, khususnya beras medium, guna mendukung formulasi kebijakan pangan di Indonesia.

Kata Kunci : BDLM, Deret Waktu, Kalman Filter

ABSTRACT

Medium-quality rice prices in Indonesia play a crucial role in maintaining economic stability and national food security. The dynamic nature of price fluctuations, influenced by seasonal factors and long-term trend changes, requires a forecasting method that is adaptive. This study applies Bayesian Dynamic Linear Models (BDLM) to forecast medium-quality rice prices using monthly data from BPS and Bapanas for the period 2014-2023. The model consists of a second-order polynomial trend component and a harmonic seasonal component under a state space framework, updated sequentially using the Kalman filter. The results indicate that BDLM effectively captures variations in both trend and seasonality with high accuracy, as reflected by a MAPE value of 4.33%. These findings are consistent with previous studies, which highlight the superior adaptive capability of Bayesian dynamic models in handling structural changes in economic time series. Therefore, BDLM can serve as a reliable alternative for forecasting food commodity prices, particularly medium-quality rice, to support food policy formulation in Indonesia.

Keywords : BDLM, Time Series, Kalman Filter

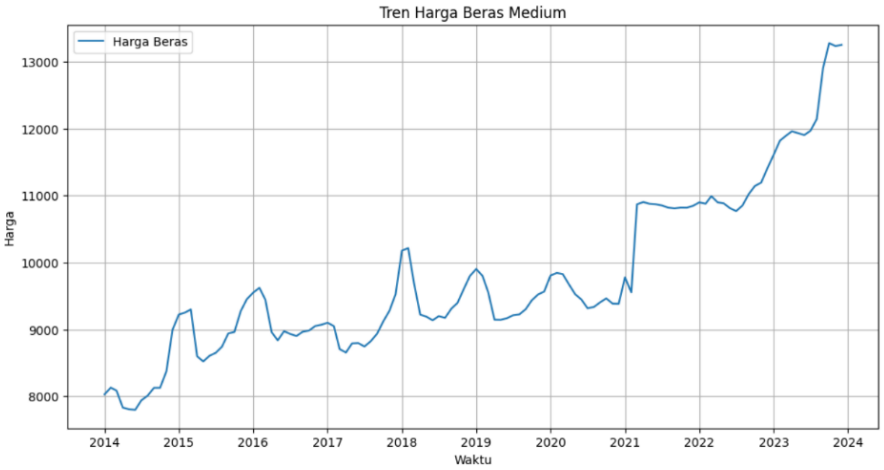
Copyright© 2025 The Author(s)..

Corresponding Author : Email : nurazizahkomararifai@unisba.ac.id*
Indexed : Garuda, Crossref, Google Scholar
DOI : https://doi.org/10.29313/jrs.v5i2.8346

A. Pendahuluan

Teorema Bayes merupakan metode penting dalam statistika untuk menghitung probabilitas bersyarat, yaitu peluang terjadinya suatu peristiwa berdasarkan informasi peristiwa lain yang terkait [1]. Dalam konteks deret waktu, pendekatan ini menjadi relevan karena sering kali dihadapkan pada keterbatasan data historis serta perubahan pola yang dinamis seiring waktu. Untuk menjawab tantangan ini, dikembangkan model dinamis berbasis bayesian yang memanfaatkan variabel keadaan (*state variables*) untuk menangkap tren, musiman, maupun pengaruh faktor eksternal secara fleksibel dan terus diperbarui seiring masuknya data baru [3].

Salah satu pendekatan yang populer dalam pemodelan deret waktu adalah *Dynamic Linear Models* (DLM), yang bekerja dalam kerangka state space dan menggunakan algoritma Kalman filter untuk memperkirakan variabel keadaan secara berurutan [4]. Dalam pendekatan ini, dikenal pula konsep *discount factor*, yang diperkenalkan oleh Harrison dan West (1997) sebagai solusi untuk mengurangi pengaruh data historis dalam perubahan variabel keadaan. Dengan demikian, model menjadi lebih adaptif terhadap perubahan pola terbaru dalam data [5]. Dalam literatur, DLM sering disebut sebagai *structural time series models* [6] atau state space models [7]. Adapun dalam konteks bayesian, istilah *Bayesian Dynamic Linear Models* (BDLM) digunakan secara eksplisit, yang memungkinkan pembaruan estimasi variabel keadaan secara berurutan dengan menerapkan teorema bayes [8]. Secara umum, DLM memiliki dua komponen utama, pertama yaitu persamaan observasi yang menghubungkan data pengamatan dengan variabel keadaan yang bersifat tersembunyi dan kedua yaitu persamaan sistem yang menggambarkan evolusi sistem dari waktu ke waktu dengan asumsi bahwa proses tersebut mengikuti distribusi *stokastik Gaussian* Dalam penerapannya, BDLM dapat mengombinasikan berbagai struktur komponen antara *first orde polynomial* (*local level*) untuk model linear, *second* atau *third orde polynomial* untuk model tren, dan *seasonal effect* untuk model musiman.



Gambar 1. Grafik Harga Beras Medium 2014-2023

Berdasarkan Gambar 1 harga beras di Indonesia tahun 2014 sampai 2023 menunjukkan pola dinamis yang ditandai oleh fluktuasi musiman, kecenderungan tren meningkat dari tahun ke tahun, serta dipengaruhi oleh berbagai faktor eksternal seperti iklim, distribusi, dan kebijakan pangan [10]. Di sisi lain, beras merupakan komoditas pangan pokok yang sangat penting di Indonesia, di mana sebagian besar masyarakat mengandalkannya sebagai makanan utama. Meskipun Indonesia termasuk produsen beras terbesar di dunia, kenaikan harga beras menjadi isu yang kompleks dan berdampak langsung pada daya beli masyarakat serta stabilitas ekonomi nasional. Menurut Badan Pusat Statistik (BPS) Indonesia, harga beras medium mengalami tren kenaikan signifikan dari Januari 2020 hingga Desember 2023. Berbagai faktor seperti kondisi *supply* & *demand*, sistem distribusi, infrastruktur pertanian, serta kebijakan impor dan ekspor menjadi penyebab utama fluktuasi tersebut.

Dalam menghadapi data harga beras yang bersifat tidak stasioner dan rentan terhadap perubahan pola dari waktu ke waktu, diperlukan metode peramalan yang mampu beradaptasi secara dinamis. Meskipun model seperti ARCH dan GARCH sering digunakan untuk menangani ketidakstabilan variansi pada data deret waktu, pendekatan tersebut lebih sesuai untuk data dengan volatilitas tinggi seperti data keuangan, dan kurang efektif dalam menangkap perubahan tren serta pola musiman. Oleh karena itu, penelitian ini menggunakan *Bayesian Dynamic Linear Models* (BDLM) karena kemampuannya dalam memodelkan tren dan musiman secara adaptif melalui pendekatan *state space* yang diperbarui secara berurutan. BDLM juga memungkinkan integrasi informasi historis dan data baru secara probabilistik, sehingga lebih tepat digunakan untuk memodelkan dinamika harga beras yang kompleks dan tidak dapat dijelaskan dengan pendekatan statis.

Salah satu aspek penting dalam memahami dinamika harga beras adalah klasifikasi jenis beras, yang dibedakan berdasarkan kadar patahnya menjadi tiga kategori yaitu premium (≤15%), medium (15,01%–25%), dan luar kualitas (>25%) [15]. Dari ketiga jenis tersebut, beras medium merupakan yang paling banyak dikonsumsi masyarakat serta paling rentan terhadap tekanan pasar [16]. Hal ini terlihat pada tahun 2022, di mana lonjakan harga beras memicu inflasi pangan hingga mencapai 5,5%. Selain itu, data harga bulanan dari 2014 hingga 2023 menunjukkan adanya pola musiman yang konsisten, khususnya saat panen raya dan menjelang hari besar keagamaan, yang turut memperkuat kompleksitas pergerakan harga beras di Indonesia.

B. Metode Penelitian

Penelitian ini menggunakan data sekunder berupa deret waktu bulanan harga rata-rata beras kualitas medium di Indonesia yang diperoleh dari dua sumber resmi, yaitu Badan Pusat Statistik (BPS) dan Badan Pangan Nasional (Bapanas). Rentang waktu data yang digunakan mencakup periode Januari 2014 hingga Desember 2023, dengan frekuensi bulanan. Data tersebut digunakan untuk membangun dan mengevaluasi model peramalan berbasis *Bayesian Dynamic Linear Models* (BDLM) dalam memprediksi harga beras medium pada tahun 2024. Langkah analisis yang akan dilakukan untuk mencapai tujuan dalam penelitian ini adalah sebagai berikut:

1. Eksplorasi data dan menentukan pola data.
2. Menentukan parameter *state vector* (θ_t).
3. Menentukan inisial $V_0 = 1$.
4. Menentukan *initial information* awal dari persamaan (1) dengan rata-rata = 0 dan kovarians $10^7 \cdot \mathrm{I}_{14}$
   $(\theta_{t-1}|D_{t-1}) \sim T_{n,t-1}[m_0, C_0]$ … (1)
5. Menentukan matriks evolusi (G_{tren}) pada persamaan (2) berdasarkan *state vector* pada tahap 1.b dan $G_{musiman}^{(j)}$ untuk musiman pada persamaan (3).
   $\theta_{tren} = G_t\theta_{t-1} + \omega_t, \qquad \omega_t \sim T_{nt-1}[0, W_t],$ … (2)

   $\theta_{musiman,t} = [s_{1,t}, s_{2,t}, \cdots, s_{p,t}]^T$ … (3)
6. Menghitung varians *Prior* (P_t) masing-masing pola dengan menggunakan persamaan (4).
   $P_t = G_t C_{t-1} G_t^T$ ... (4)
7. Menghitung W_t dari masing-masing pola menggunakan *discount factor* pada persamaan (5).
   $W_t = \dfrac{1-\delta}{\delta} P_t,$ ... (5)
8. Menggabungkan matriks G_{tren} dan $G_{musiman}^{(j)}$ serta W_t dari masing-masing pola
9. Menghitung estimasi *mean* (a_t) dan kovarians (r_t) distribusi *Prior* pada waktu t pada persamaan (6).
   $a_t = G_t m_{t-1}, \qquad R_t = G_t C_{t-1} G_t^T + Z W_t$ ... (6)
10. Menentukan *vector* F_t pada persamaan (7) untuk masing-masing pola.
    $y_t = F_t^T \theta_t + v_t,\ v_t \sim N[0, V_t]$ ... (7)
11. Menggabungkan *vector* F_t dari persamaan pola seperti persamaan.

12. Menghitung Prediksi rata-rata (f_t) dan varians (q_t) dari distribusi prediksi satu langkah ke depan pada waktu t menggunakan persamaan (8).

$$f_t = F_t^T a_t, \qquad q_t = F_t^T R_t F_t + V_t \quad \text{... (8)}$$

13. Menghitung *kalman gain* (A_t) menggunakan persamaan (9).

$$A_t = \frac{R_t F_t}{q_t} \quad \text{... (9)}$$

14. Menghitung *mean* (m_t) dan kovarians (C_t) dari distribusi *posterior* menggunakan persamaan (10).

$$m_t = a_t + A_t e_t, \qquad C_t = R_t - A_t q_t A_t^T \quad \text{... (10)}$$

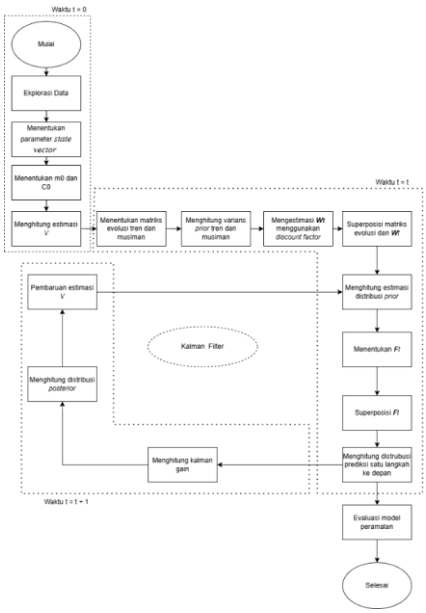
15. Melakukan pembaruan untuk estimasi (V_t) dengan menggunakan persamaan (11) dan (12) sampai iterasi $y_{t+(n-1)}$.

$$n_t = n_{t-1} + 1 \quad \text{... (11)}$$

$$d_t = d_{t-1} + \left(\frac{e_t^2}{q_t} - 1\right) \quad \text{... (12)}$$

16. Iterasi untuk t = $y_{t(n-1)}$.
17. Evaluasi model peramalan (*forecasting*) menggunakan persamaan (13).

$$\frac{1}{n}\sum_{i}^{n}\frac{ei}{yi}x100 \quad \text{... (13)}$$



Gambar 2. Diagram Alir Langkah-Langkah

C. Hasil dan Pembahasan

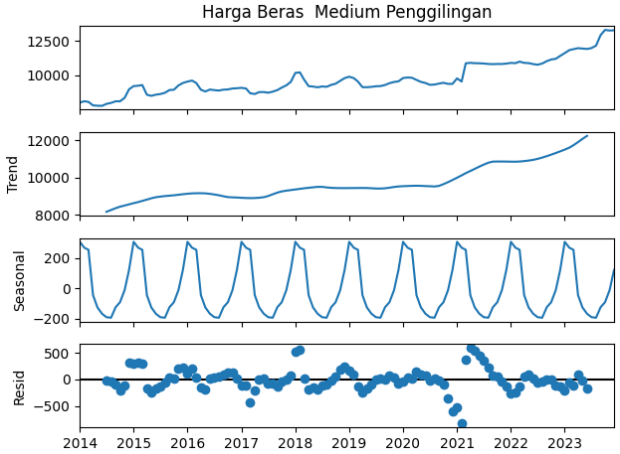
Eksplorasi Data dan Penentuan Pola Data

Berikut adalah *output* dari eksplorasi data:

Tabel 1. Dekomposisi Data Harga Beras 2014-2023

Bulan	Asli	Tren	Musiman
01/01/2014	8028,48		305,8201
01/02/2014	8129,02		267,155
01/03/2014	8083,86		253,4426
01/04/2014	7830,22		-44,6551

Bulan	Asli	Tren	Musiman
01/05/2014	7805,76		-125,569
⋮	⋮	⋮	⋮
01/12/2023	13254		120,8336



Gambar 3. Pola Data

Penentuan Parameter *State Vector* ($\boldsymbol{\theta_t}$)

Pemodelan ini akan ditentukan komponen tren polinomial orde kedua untuk menangkap tren tersebut dan komponen musiman dengan periode (p) = 12 untuk mengakomodasi pola musiman.

1. Tren : $\theta_{trend,t} = \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix}$

   di mana:

   μ_t adalah *local level* (tingkat harga rata-rata).

   β_t adalah *slope* (laju perubahan atau tren).

2. Musiman :$\theta_{musiman,t} = \begin{bmatrix} s_{1,t} \\ s_{2,t} \\ \vdots \\ s_{p,t} \end{bmatrix}$ dengan $p = 12$

Penentuan Varians Awal ($\boldsymbol{V_0}$)

$$V_0 = S_0 = \frac{1}{1} = 1$$

Nilai ini menunjukkan bahwa varians awal diasumsikan sebesar 1. Asumsi ini digunakan sebagai titik tolak sebelum dilakukan pembaruan posterior melalui proses *filtering*.

Penentuan *Initial Information* ($\boldsymbol{m_0}$ & $\boldsymbol{C_0}$)

$$m_0 = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}_{14\times1}, C_0 = 10^7 \cdot \mathrm{I}_{14} = 10^7 \cdot \begin{bmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & \dots & 1 \end{bmatrix}_{14\times14}$$

Pendekatan ini menunjukkan bahwa nilai awal setiap komponen dianggap sangat tidak pasti, sehingga model dapat menyesuaikan parameter sepenuhnya berdasarkan data. Hal ini sesuai dengan prinsip bayesian yang menggunakan *Prior* lemah (*Weakly Informative Prior*), di mana estimasi lebih dipengaruhi oleh data observasi dari pada asumsi awal.

Penentuan Matriks Transisi (G_t)

Matriks transisi G_t untuk komponen tren adalah:

$$G_{tren,t} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

Adapun untuk komponen musiman nonparametrik dengan periode 12, digunakan pendekatan rotasi siklikal:

$$G_{musiman,t} = \begin{pmatrix} 0 & 0 & 0 & \dots & 1 \\ 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & \dots & 0 \end{pmatrix}_{12\times 12}$$

Menghitung Varians *Prior* Awal (P_t)

Varians *Prior* komponen tren:

$$\begin{aligned} P_{tren,1} &= G_{tren} C_{0,tren} G_{tren}^T \\ &= \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \cdot 10^7 \cdot \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \\ &= 10^7 \cdot \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \end{aligned}$$

Komponen musiman nonparametrik dengan periode 12 dan merupakan matriks pergeseran siklikal, maka perhitungannya juga:

$$P_{musiman,1} = G_{musiman} C_{0,musiman} G_{musiman}^T$$

Sehingga:

$$P_{musiman,1} = 10^7 \cdot I_{12}$$

Menghitung Estimasi W_t

Kovarians evolusi untuk komponen tren sebagai berikut:

$$W_{tren,1} = \frac{1-0.98}{0.98} 10^7 \cdot \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} = 0.0204082 \cdot 10^7 \cdot \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$$

$$W_{tren,1} = \begin{pmatrix} 408162 & 204081 \\ 204081 & 204081 \end{pmatrix}$$

Kovarians evolusi untuk komponen musiman sebagai berikut:

$$W_{musiman,1} = \frac{1-0.98}{0.98} 10^7 \cdot \mathrm{I}_{12} = 0.0204082 \cdot 10^7 \cdot \mathrm{I}_{12}$$

Superposisi Matriks Transisi G_t dan Kovarians Evolusi W_t

$$G_t = \begin{pmatrix} 1 & 1 & 0 & \dots & 0 \\ 0 & 0 & 0 & \dots & 1 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & 1 \\ 0 & 0 & \dots & 0 & 0 \end{pmatrix}_{14\times 14}$$

$$W_t = \begin{pmatrix} 408163.27 & 204081.63 & 0 & \dots & 0 \\ 204081.63 & 204081.63 & 0 & \dots & 0 \\ 0 & 0 & 204081.63 & \ddots & \vdots \\ \vdots & \vdots & \dots & 0 & \vdots \\ 0 & 0 & \dots & 0 & 204081.63 \end{pmatrix}_{14\times 14}$$

Dengan demikian $W_{musiman,1}$ berbentuk matriks 12 × 12, dimana seluruh nilai diagonalnya $0.0204082 \cdot 10^7$, dan elemen lainnya nol.

Distribusi *Prior* pada waktu (t = 1): *Mean Prior* (a_t)

Tabel 2. Iterasi *Mean Prior*

a_t	latent_state1	latent_state2	latent_state3	…	latent_state13	latent_state14
1	0	0	0	…	0	0
2	7277.8267	104.3583	822.3882	…	1024.1995	955.5514
3	7330.8721	77.7065	450.1710	…	966.8557	830.6951
4	7453.8471	78.3456	360.9071	…	893.3842	454.7181
5	7505.9627	64.7556	320.9568	…	474.8219	364.5527
⋮	⋮	⋮	⋮	⋮	⋮	⋮
120	12326.0753	44.6103	1031.3674	…	903.1914	979.9562

Distribusi *Prior* pada waktu (t = 1): *Kovarians Prior* (R_1)

$$\begin{pmatrix} 2.04 \times 10^7 & 1.02 \times 10^7 & \dots & 0 \\ 1.02 \times 10^7 & 1.02 \times 10^7 & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}_{14\times14}$$

Untuk iterasi selanjutnya sama saja rumusnya.

Distribusi *Prior* pada waktu (t = 1): Penentuan Vektor Transisi (F_t)
Untuk komponen tren, digunakan matriks observasi $F_{tren,t}$ = [1 0]
Untuk komponen musiman, digunakan vektor transisi $F_{musiman,t} = [1\ 0\ 0\ \cdots\ 0]_{12\times1}$

Superposisi F_t

$$F_t = [\,1 \quad 0 \quad 1 \quad \cdots \quad 0\,]_{1\times14}$$

Prediksi Satu Langkah ke Depan

Tabel 3. Iterasi Prediksi Satu Langkah ke Depan

Date	Mean	Variance	Residual
01/01/2014	0	30303031	8028.48
01/02/2014	8028.48	47858346	100.5403
01/03/2014	10805.18	28649997	-2721.32
01/04/2014	11133.7	20259456	-3303.48
01/05/2014	10700.45	16359089	-2894.69
⋮	⋮	⋮	⋮
01/11/2023	13387.06	60853.98	-151.058

Menghitung *Kalman Gain* A_t
Berikut *output* nya:

Tabel 4. *Kalman Gain* A_t

A_t	latent_state1	latent_state2	latent_state3	…	latent_state13	latent_state14
1	0.65	0.32	0.32	…	0	0
2	0.15	0.50	0.87	…	-0.51	-0.25
3	0.11	0.29	0.93	…	-0.49	-0.24
4	0.81	0.19	0.94	…	-0.43	-0.22
5	0.65	0.32	0.95	…	-0.39	-0.21
⋮	⋮	⋮	⋮	⋮	⋮	⋮
120	0.18	0.29	-0.12	…	-0.17	-0.15

Menghitung *mean posterior* (m_t) dan *kovarians posterior* (C_t)
Sebagai contoh berikut ditampilkan hasil perhitungan untuk waktu t = 1:

Mean posterior $(\boldsymbol{m_t})$

Tabel 5. *Mean Posterior* (m_t) dan *Kovarians Posterior* (C_t)

m_t	latent_state1	latent_state2	latent_state3	…	latent_state13	latent_state14
1	5352.3198	2676.1599	2676.1599	…	0	0
2	8095.5066	2709.6733	33.5134	…	0	2643.3168
3	9104.3550	2029.3434	-1020.4949	…	2970.0112	1033.5984
4	9271.7378	1428.7110	-1441.5177	…	1668.1305	215.6065
5	9240.0653	1037.5368	-1434.3051	…	866.7915	-393.6926
⋮	⋮	⋮	⋮	⋮	⋮	⋮
120	12194.8683	44.2604	1059.1320	…	948.0773	986.6087

Kovarians Posterior $(\boldsymbol{C_t})$

$$C_1 = \begin{pmatrix} 10528836.1711 & 5264418{,}0855 & \cdots & 0 \\ 5264418{,}0855 & 10528835{,}6499 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 15793253{,}2143 \end{pmatrix}_{14\times14}$$

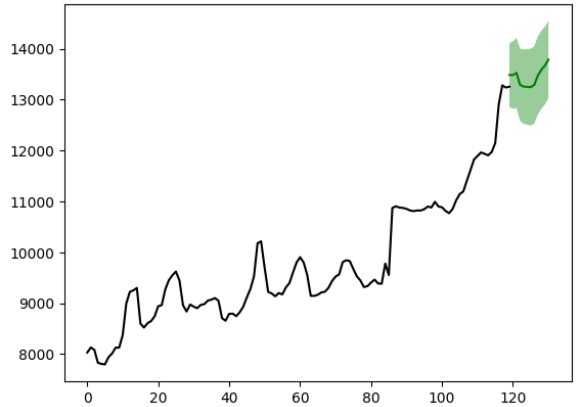
Dan waktu t seterusnya

Melakukan Pembaruan Estimasi V

Tabel 6. Pembaruan Estimasi V

Date	n_t	d_t	s_t
01/01/2014	2	2.1270	8028.48
01/02/2014	3	1.1272	100.5403
01/03/2014	4	0.3857	-2721.32
01/04/2014	5	-0.0755	-3303.48
01/05/2014	6	-0.5633	-2894.69
⋮	⋮	⋮	⋮
01/12/2023	121	86.7668	0.7170

Prediksi K-Langkah ke Depan
Berikut ditampilkan *output* grafik dan tabel nya:

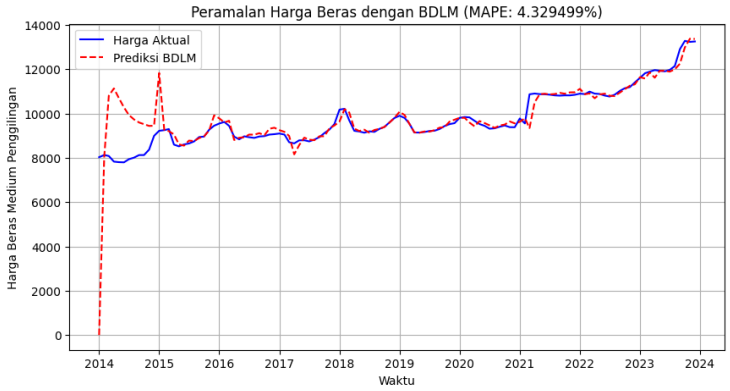


Gambar 4. Grafik Prediksi K-Langkah ke Depan

Tabel 7. Grafik Prediksi K-Langkah ke Depan

K-langkah	Mean (μ)	Varians (σ^2)	Std Dev (σ)	Rentang 95% CI
1	13481.39	103117.26	321.03	[12,852.17 – 14,110.61]
2	13482.33	113846.36	337.32	[12,820.42 – 14,144.23]
3	13523.14	123269.99	351.10	[12,835.98 – 14,210.30]
4	13290.47	131393.14	362.51	[12,579.97 – 14,000.97]
5	13254.77	138225.54	371.72	[12,526.20 – 13,983.34]
6	13250.26	143771.16	379.10	[12,507.18 – 13,993.34]
7	13243.93	148027.26	384.82	[12,489.73 – 13,998.13]
8	13287.97	150985.05	388.63	[12,526.26 – 14,049.69]
9	13471.38	152630.81	390.69	[12,705.65 – 14,237.11]
10	13585.55	152947.31	391.12	[12,818.97 – 14,352.13]
11	13668.34	151915.76	389.78	[12,904.38 – 14,432.30]
12	13785.13	149518.46	386.83	[13,026.85 – 14,543.40]

Evaluasi Model Peramalan (*Forecasting*)



Gambar 5. Grafik Data Aktual dan Prediksi

Berdasarkan grafik di atas menunjukkan hasil peramalan harga beras medium tingkat penggilingan menggunakan model *Bayesian Dynamic Linear Models* (BDLM) pada periode 2014–2023, dengan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 4.33%. Garis biru merepresentasikan data aktual, sementara garis merah putus-putus menunjukkan hasil prediksi model. Secara visual, model mampu mengikuti pola tren dan fluktuasi musiman yang terjadi pada data, termasuk menangkap lonjakan harga secara tiba-tiba serta variasi tahunan. Nilai MAPE yang rendah menunjukkan bahwa model memiliki tingkat akurasi yang sangat baik, sehingga dapat dikatakan bahwa BDLM cukup andal untuk memodelkan dan memprediksi dinamika harga beras selama periode pengamatan.

D. Kesimpulan

Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, dapat disimpulkan bahwa model *Bayesian Dynamic Linear Models* (BDLM) berhasil diterapkan untuk memodelkan dan meramalkan harga rata-rata bulanan komoditas beras medium di Indonesia. Model ini dibangun menggunakan kombinasi komponen tren polinomial orde kedua dan komponen musiman harmonik, yang mampu menangkap dinamika data yang kompleks, termasuk tren kenaikan jangka panjang dan pola siklus tahunan yang berulang. Evaluasi kinerja model menunjukkan tingkat akurasi yang sangat tinggi, dengan nilai *Mean Absolute Percentage Error* (MAPE) sebesar 4,33%, yang mengindikasikan bahwa model sangat akurat dalam memprediksi harga beras medium. Maka model yang didapat sangat baik untuk meramalkan data beras medium di Indonesia.

Daftar Pustaka

[1] N. Paramitha, E. Junianto, and S. Susanti, "Penerapan Teorema Bayes untuk Diagnosis Penyakit pada Ibu Hamil Berbasis Android," *Jurnal Informatika*, vol. 6, no. 1, pp. 53–61, 2019, doi: 10.31311/ji.v6i1.4693.

[2] G. Salma and T. S. Yanti, "Pemodelan Intervensi untuk Meramalkan Jumlah Penumpang Pesawat Domestik Bandara Internasional Sultan Hasanuddin Makassar," *Jurnal Riset Statistika*, pp. 67–74, Aug. 2024, doi: 10.29313/jrs.v4i1.3892.

[3] M. Laine, "Introduction to *Dynamic Linear Models* for Time Series Analysis," pp. 139–156, 2029, doi: 10.1007/978-3-030-21718-1_4.

[4] M. West and J. Harisson, *Bayesian forecasting and dynamic models (2nd edn)*, vol. 49, no. 2. 1997. doi: 10.1057/palgrave.jors.2600494.

[5] A. Yusupova, N. G. Pavlidis, and E. G. Pavlidis, "*Dynamic Linear Models* with adaptive discounting," *Int J Forecast*, vol. 39, no. 4, pp. 1925–1944, 2023, doi: 10.1016/j.ijforecast.2022.09.006.

[6] J. T. Jalles, "Structural Time Series Models and the Kalman Filter: A Concise Review," *SSRN Electronic Journal*, pp. 1–30, 2011, doi: 10.2139/ssrn.1496864.

[7] S. M. Miraftabzadeh, C. G. Colombo, M. Longo, and F. Foiadelli, "K-Means and Alternative Clustering Methods in Modern Power Systems," *IEEE Access*, vol. 11, no. September, pp. 119596–119633, 2023, doi: 10.1109/ACCESS.2023.3327640.

[8] G. Petris, P. Campagnoli, and S. Petrone, "*Dynamic Linear Models* with R," *Dynamic Linear Models with R*, no. June 2009, 2009, doi: 10.1007/b135794.

[9] A. S. Budiman and N. Hajarisman, "Analisis Mediasi Multipel Paralel Kausal Step pada Data Stunting menurut Kabupaten/Kota," *Jurnal Riset Statistika*, pp. 31–40, Jul. 2024, doi: 10.29313/jrs.v4i1.3860.

[10] W. Arifin, I. S. Rianse, H. Sudarmo, and U. H. Oleo, "Analisis Fluktuasi Harga Beras Di Tingkat Petani, Pedagang, Dan Pengecer Di Kota Kendari," vol. 2, no. 1, pp. 36–48, 2024.

[11] Adila Yuniantini and Ilham Faishal Mahdy, "Implementasi K-Medoids dan FP-Growth pada Pola Konsumen Tempat Makan Bandung," *Jurnal Riset Statistika*, pp. 47–56, Jul. 2025, doi: 10.29313/jrs.v5i1.6529.

[12] Aida Nurul Islah and Teti Sofia Yanti, "Peramalan Jumlah Kunjungan Pasien Balita dengan Metode Holt's Double Exponential Smoothing," *Jurnal Riset Statistika*, pp. 119–126, Dec. 2024, doi: 10.29313/jrs.v4i2.5026.

[13] Raisa Filmi Suryahadikusumah and Sutawanir Darwis, "Penentuan Premi Asuransi Gempa Berdasarkan Declustering Katalog Jawa Barat," *Jurnal Riset Statistika*, pp. 127–136, Dec. 2024, doi: 10.29313/jrs.v4i2.5029.

[14] Muhammad Fariz Faqih, Trianto Syahbanu Prayoga, Ammaar Dzakiir, and Puri Indah Lestari, "Klasifikasi Penentuan Pengajuan Kartu Kredit Menggunakan K-Nearest Neighbors (KNN)," *Jurnal Riset Statistika*, pp. 85–92, Jul. 2025, doi: 10.29313/jrs.v5i1.5921.

[15] J. H. David and T. Kartinaty, "Karakteristik Mutu Beras Di Berbagai Penggilingan Pada Sentra Padi Di Kalimantan Barat," *Journal TABARO Agriculture Science*, vol. 3, no. 1, p. 276, 2019, doi: 10.35914/tabaro.v3i1.197.

[16] S. Kasnelly, I. M. Khusna, J. Khairiah, Lisa, and M. Qibthiah, "Kenaikan Harga Beras di Indonesia," vol. 7, no. Juli, pp. 1–10, 2024.