BAB III

METODOLOGI

III.1 Jenis Penelitian

Penelitian ini merupakan penelitian eksperimen dengan pendekatan kuantitatif dan desain komparatif untuk melakukan klasifikasi spesies dan gejala visual pada daun *Hoya*. Kinerja model dinilai menggunakan ukuran numerik berupa *accuracy*, *precision*, *recall*, F1-score, dan F1-Macro yang diperoleh dari proses pengujian.

Eksperimen membandingkan tiga arsitektur *backbone* CNN, yaitu ResNet-50, DenseNet-121, dan VGG16, menggunakan konfigurasi yang sama. Konfigurasi tersebut mencakup bobot pralatih ImageNet, CBAM, pendekatan *multi-task learning*, Focal Loss, *optimizer*, augmentasi data pelatihan, *WeightedRandomSampler*, pembagian dataset, dan prosedur evaluasi. Klasifikasi dilakukan melalui dua tugas, yaitu klasifikasi spesies dan gejala visual pada daun. Kedua tugas diterapkan dalam satu model *multi-task learning* sehingga satu citra menghasilkan dua keluaran prediksi melalui representasi fitur bersama.

Ketiga arsitektur menggunakan bobot pralatih ImageNet melalui pendekatan *transfer learning* dan dilatih sebanyak lima *run* dengan *random seed* yang berbeda. Penggunaan konfigurasi yang seragam bertujuan menjaga kesetaraan perlakuan antararsitektur. Dengan demikian, penelitian berfokus pada perbandingan kinerja *backbone*, bukan mengukur kontribusi CBAM, Focal Loss, *WeightedRandomSampler*, Mixup, CutMix, atau komponen lain secara individual. Pengukuran kontribusi setiap komponen memerlukan eksperimen *ablation* yang tidak dilakukan dalam penelitian ini [30].

III.2 Lokasi dan Waktu Penelitian

Penelitian dilaksanakan sebagai bagian dari kegiatan Magang Mandiri di Badan Riset dan Inovasi Nasional (BRIN), khususnya pada Kelompok Riset *Knowledge and Data Engineering*, Pusat Riset Sains Data dan Informasi, Organisasi Riset Elektronika dan Informatika. Penelitian berlangsung pada 17 Juni 2026 sampai 15 Agustus 2026.

Kegiatan meliputi studi literatur, pengumpulan dan pemeriksaan data, pelabelan, *preprocessing* citra, pembangunan model, pelatihan, pengujian, evaluasi, serta analisis hasil. Seluruh kegiatan dilaksanakan secara bertahap agar proses penelitian berlangsung secara sistematis.

Tabel III.1: Lokasi dan waktu penelitian

Komponen	Keterangan
Instansi	Badan Riset dan Inovasi Nasional (BRIN)
Kelompok Riset	*Knowledge and Data Engineering*
Pusat Riset	Pusat Riset Sains Data dan Informasi
Organisasi Riset	Organisasi Riset Elektronika dan Informatika
Jenis kegiatan	Magang Mandiri
Waktu penelitian	17 Juni 2026–15 Agustus 2026
Kegiatan utama	Pengumpulan data, prapemrosesan, pemodelan, pelatihan, evaluasi, dan analisis

III.3 Sumber Data

Data citra penelitian terdiri atas data primer dan data sekunder. Data primer diperoleh melalui dokumentasi langsung oleh peneliti, sedangkan data sekunder berupa citra yang diperoleh dari sumber daring. Literatur ilmiah tidak diperlakukan sebagai bagian dari dataset citra, tetapi digunakan sebagai dasar teoritis dan metodologis penelitian.

III.3.1 Data Primer

Data primer diperoleh melalui dokumentasi langsung terhadap spesimen *Hoya* yang tersedia. Citra diambil secara langsung oleh peneliti dari tanaman koleksi yang menjadi objek penelitian. Data tersebut dikategorikan sebagai data primer karena diperoleh langsung dari objek penelitian melalui proses dokumentasi oleh peneliti.

III.3.2 Data Sekunder

Data sekunder berupa citra daun *Hoya* yang diperoleh melalui pencarian pada platform media sosial, seperti Instagram, Facebook, dan Reddit. Citra tersebut dikategorikan sebagai data sekunder karena berasal dari unggahan pihak lain dan bukan hasil dokumentasi langsung oleh peneliti. Sebelum digunakan, setiap citra melalui pemeriksaan kualitas, verifikasi objek, dan pelabelan spesies serta gejala visual pada daun. Citra sekunder digunakan untuk melengkapi dataset, terutama pada spesies atau kategori gejala visual yang memiliki jumlah dokumentasi terbatas.

III.4 Deskripsi Dataset

Dataset penelitian berupa citra daun *Hoya* yang memiliki dua informasi target, yaitu spesies dan gejala visual pada daun. Dataset awal terdiri atas 2.214 citra dari 10 spesies *Hoya* dan lima kelas gejala visual setelah dilakukan pemeriksaan kualitas serta penghapusan kelas Bercak Bintik Hitam Putih sebagaimana dijelaskan pada bagian III.6. Karakteristik berupa bentuk, warna, tekstur, dan permukaan daun digunakan sebagai informasi visual dalam kedua tugas klasifikasi. Setiap citra memiliki label spesies dan label gejala visual pada daun yang digunakan secara bersamaan sebagai target dalam model *multi-task learning*. Kelima kelas gejala ditetapkan berdasarkan karakteristik citra dan tidak dimaksudkan sebagai diagnosis penyakit secara klinis maupun patologis.

Tabel III.2: Karakteristik dataset

Karakteristik	**Keterangan**
Jenis data	Citra daun *Hoya*
Jumlah citra awal	2.214 citra
Jumlah citra yang digunakan dalam eksperimen	2.213 citra
Jumlah spesies	10 spesies
Jumlah kelas gejala visual pada daun	5 kelas
Target klasifikasi	Spesies dan gejala pada daun
Ukuran citra setelah prapemrosesan	224×224 piksel
Pembagian dataset	70% : 15% : 15%
Data pelatihan	1.551 citra
Data validasi	329 citra
Data pengujian	333 citra

Dataset awal berjumlah 2.214 citra, sedangkan dataset final yang digunakan dalam eksperimen berjumlah 2.213 citra. Selisih satu citra berasal dari satu citra berlatar belakang putih pada subset validasi awal yang dikeluarkan dan tidak digantikan. Pengeluaran tersebut dilakukan karena data validasi dan pengujian menggunakan citra berlatar belakang alami, sedangkan tidak terdapat citra pengganti dari kelompok daun yang sama yang memenuhi kriteria tersebut. Jumlah dataset final tersebut sesuai dengan penjumlahan 1.551 citra pelatihan, 329 citra validasi, dan 333 citra pengujian.

III.4.1 Jenis Spesies Hoya

Dataset mencakup 10 spesies *Hoya* dengan jumlah citra yang berbeda. Perbedaan jumlah sampel menunjukkan bahwa distribusi data antarkelas belum sepenuhnya seimbang. Kondisi tersebut perlu diperhatikan dalam proses pelatihan karena jumlah informasi yang diterima model dari setiap kelas tidak sama. Contoh citra setiap spesies ditampilkan pada Gambar III.1.



Gambar III.1: Citra daun Hoya berdasarkan spesies

Gambar III.1 menampilkan contoh citra daun dari 10 spesies *Hoya*. Perbedaan bentuk, warna, tekstur, dan pola permukaan menjadi karakteristik visual yang dipelajari oleh model. Kemiripan morfologi antarkelas juga terlihat pada citra sehingga memberikan gambaran mengenai kompleksitas klasifikasi spesies. Distribusi pada tabel berikut menunjukkan karakteristik dataset awal sebelum penyaringan satu citra pada tahap pembagian dataset.

Tabel III.3: Distribusi citra berdasarkan spesies Hoya

No.	Spesies	Jumlah Citra	Proporsi
1	*Hoya lacunosa*	346	15,63%
2	*Hoya kerrii*	289	13,05%
3	*Hoya finlaysonii*	237	10,70%
4	*Hoya australis*	236	10,66%
5	*Hoya carnosa*	230	10,39%
6	*Hoya macrophylla*	218	9,85%
7	*Hoya wayetii*	182	8,22%
8	*Hoya callistophylla*	172	7,77%
9	*Hoya imperialis*	165	7,45%
10	*Hoya pubicalyx*	139	6,28%
	Total	**2.214**	**100%**

Hoya lacunosa memiliki jumlah citra paling banyak, yaitu 346 citra, sedangkan *Hoya pubicalyx* memiliki jumlah paling sedikit, yaitu 139 citra. Ketidakseimbangan tersebut menjadi pertimbangan dalam strategi *sampling* dan evaluasi model.

III.4.2 Jenis Gejala pada Daun

Klasifikasi gejala didasarkan pada karakteristik visual yang tampak pada citra daun. Dataset terdiri atas lima kelas, yaitu Sehat, Daun Layu, Bercak Putih, Bercak Bintik Hitam, dan Bercak Cokelat. Kelima kategori tersebut merepresentasikan gejala visual yang terlihat pada permukaan daun dan tidak digunakan sebagai diagnosis penyakit secara klinis maupun patologis. Contoh setiap kategori ditampilkan pada Gambar III.2.



Gambar III.2: Citra daun Hoya berdasarkan gejala

Gambar III.2 memperlihatkan contoh citra dari lima kategori gejala visual pada daun. Distribusi pada tabel berikut menunjukkan karakteristik dataset awal sebelum penyaringan satu citra pada tahap pembagian dataset.

Tabel III.4: Distribusi citra berdasarkan gejala pada daun

No.	Gejala Daun	Jumlah Citra	Proporsi
1	Sehat	957	43,23%
2	Daun Layu	348	15,72%
3	Bercak Putih	328	14,82%
4	Bercak Bintik Hitam	301	13,59%
5	Bercak Cokelat	280	12,64%
	Total	**2.214**	**100%**

Kelas Sehat memiliki jumlah citra terbesar, yaitu 957 citra atau 43,23%, sedangkan Bercak Cokelat memiliki jumlah terkecil, yaitu 280 citra atau 12,64%. Distribusi tersebut menunjukkan adanya ketidakseimbangan kelas yang perlu ditangani selama proses pembelajaran.

III.4.3 Pembagian Dataset

Dataset dibagi menjadi data pelatihan, validasi, dan pengujian dengan proporsi 70%:15%:15%. Pembagian dilakukan secara terstratifikasi berdasarkan kombinasi kelas spesies dan gejala visual pada daun dengan menggunakan kelompok daun (*leaf ID*) sebagai unit pembagian. *Leaf ID* merupakan identitas unik yang dibentuk dari gabungan nama spesies dan nama dasar berkas citra setelah akhiran penanda latar belakang putih dihilangkan, seperti `_whitebg`, `_white`, `_putih`, dan variasi sejenis. Dengan demikian, citra berlatar belakang berbeda yang berasal dari daun fisik yang sama memperoleh *leaf ID* yang sama dan tidak ditempatkan pada subset berbeda. Pembagian dilakukan menggunakan *random seed* 42 agar subset pelatihan, validasi, dan pengujian tetap sama pada seluruh eksperimen. Pengelompokan berdasarkan *leaf ID* digunakan untuk mencegah citra dari daun fisik yang sama masuk ke subset pelatihan, validasi, dan pengujian secara bersamaan sehingga risiko *data leakage* pada tingkat individu daun dapat dikurangi [26]. Setelah pembagian dilakukan, data validasi dan pengujian hanya menggunakan citra berlatar belakang alami, sedangkan citra berlatar belakang putih tetap dapat digunakan pada data pelatihan.

Tabel III.5: Pembagian dataset

Subset	Proporsi	Fungsi
Pelatihan	70%	Melatih dan memperbarui parameter model
Validasi	15%	Memantau kinerja dan menentukan *checkpoint* terbaik
Pengujian	15%	Mengukur kinerja akhir model
Total	**100%**	

III.5 Variabel Penelitian dan Definisi Operasional

Variabel penelitian mencakup citra daun sebagai masukan model, spesies dan gejala visual pada daun sebagai target prediksi, arsitektur CNN sebagai variabel eksperimen, serta metrik evaluasi sebagai ukuran kinerja. Setiap arsitektur memiliki karakteristik

konektivitas yang berbeda. ResNet-50 menggunakan *residual connection*, DenseNet-121 menerapkan *dense connectivity*, sedangkan VGG16 menggunakan susunan lapisan konvolusi secara berurutan.

Tabel III.6: Variabel penelitian dan definisi operasional

Variabel	**Jenis**	**Definisi Operasional**
Citra daun *Hoya*	Masukan	Citra digital daun yang diberikan sebagai masukan model.
Spesies *Hoya*	Target	Jenis spesies yang diprediksi model.
Gejala visual pada daun	Target	Kategori gejala visual yang diprediksi model berdasarkan karakteristik citra.
ResNet-50	Variabel eksperimen	Arsitektur CNN yang menggunakan *residual connection*.
DenseNet-121	Variabel eksperimen	Arsitektur CNN yang menggunakan *dense connectivity*.
VGG16	Variabel eksperimen	Arsitektur CNN dengan susunan lapisan konvolusi bertingkat.
Transfer learning	Metode	Pemanfaatan bobot pralatih ImageNet.
CBAM	Modul model	Modul perhatian untuk menekankan fitur yang relevan.
Multi-task learning	Metode	Pembelajaran spesies dan gejala visual pada daun secara simultan.
Focal Loss	Fungsi kerugian	Fungsi *loss* yang memberikan penekanan lebih besar pada sampel sulit.
Accuracy	Metrik	Proporsi prediksi yang diklasifikasikan secara benar.
Precision	Metrik	Ketepatan prediksi terhadap suatu kelas.
Recall	Metrik	Kemampuan model menemukan sampel dari suatu kelas.
F1-score	Metrik	Ukuran keseimbangan antara *precision* dan *recall*.
F1-Macro	Metrik	Rata-rata F1-score dari seluruh kelas.

III.6 Metode Pengumpulan Data

Pengumpulan data dilakukan melalui dokumentasi langsung terhadap spesimen *Hoya* yang tersedia serta pengumpulan citra sekunder dari unggahan komunitas pada media sosial. Dataset awal yang dibangun berjumlah 2.214 citra dari 10 spesies. Setiap citra diperiksa berdasarkan keberadaan objek daun, kualitas visual, serta kesesuaian label spesies dan gejala visual pada daun. Proses pelabelan membentuk 10 kelas spesies dan lima kelas gejala visual. Pada tahap pemeriksaan label, kelas Bercak Bintik Hitam Putih dihapus sehingga tugas klasifikasi gejala visual pada daun terdiri atas lima kelas yang digunakan dalam penelitian.

III.7 Metode Analisis Data

Analisis data mencakup *preprocessing* citra, pembagian dataset, augmentasi data, pembangunan dan pelatihan model, evaluasi kinerja, analisis kesalahan klasifikasi, serta analisis interpretabilitas. Ketiga arsitektur CNN menggunakan konfigurasi eksperimen yang sama sehingga hasil perbandingan dapat dianalisis secara konsisten.

III.7.1 Preprocessing Citra

Preprocessing diterapkan secara seragam pada seluruh citra sebelum citra digunakan sebagai masukan model. Tahapan ini bertujuan menyelaraskan karakteristik dasar citra yang berasal dari sumber dan kondisi pengambilan yang beragam, terutama dalam aspek ketajaman, kontras, ukuran, dan rentang nilai piksel. Tahapan *preprocessing* yang diterapkan adalah sebagai berikut.

1. Pemeriksaan ketajaman dan penajaman adaptif (*adaptive sharpening*). Ketajaman citra diukur menggunakan varians operator Laplacian pada citra *grayscale*. Citra dengan nilai varians kurang dari 100,0 dikategorikan kurang tajam dan diberikan proses *unsharp masking* dengan *sharpen strength* sebesar 1,2. Citra dengan nilai varians minimal 100,0 tidak diberikan penajaman tambahan.
2. Peningkatan kontras menggunakan *Contrast Limited Adaptive Histogram Equalization* (CLAHE). CLAHE diterapkan pada kanal luminansi (L) dalam ruang warna LAB dengan *clip limit* 2,0 dan ukuran *tile grid* 8×8. Tahapan tersebut bertujuan meningkatkan kontras lokal sehingga karakteristik permukaan dan gejala visual pada daun lebih mudah dibedakan, khususnya pada citra dengan pencahayaan tidak merata.
3. Perubahan ukuran citra. Seluruh citra diubah menjadi ukuran 224×224 piksel sesuai dengan ukuran masukan yang digunakan oleh ketiga *backbone*.
4. Normalisasi nilai piksel. Nilai piksel dinormalisasi menggunakan parameter ImageNet, yaitu rata-rata $[0{,}485; 0{,}456; 0{,}406]$ dan standar deviasi $[0{,}229; 0{,}224; 0{,}225]$ untuk kanal RGB.

Keempat tahapan tersebut diterapkan pada data pelatihan, validasi, pengujian, dan proses TTA sehingga citra memperoleh perlakuan *preprocessing* dasar yang konsisten pada seluruh tahapan eksperimen.

III.7.2 Augmentasi Data

Augmentasi diterapkan hanya pada data pelatihan untuk meningkatkan keragaman citra dan membantu model mempelajari representasi yang lebih *robust*. Konfigurasi augmentasi yang digunakan meliputi:

1. Perubahan ukuran awal menjadi 1,15 kali ukuran target atau 257×257 piksel;
2. Rotasi acak pada salah satu sudut $0°$, $90°$, $180°$, atau $270°$;
3. *Horizontal flip* dengan probabilitas 0,5;

4. *Vertical flip* dengan probabilitas 0,3;
5. RandAugment dengan *num_ops* 2 dan *magnitude* 9;
6. *Random resized crop* menjadi 224×224 piksel dengan rentang skala 0,75–1,0;
7. *Color jitter* dengan *brightness* 0,15, *contrast* 0,10, dan *saturation* 0,08;
8. *Random erasing* dengan probabilitas 0,25, luas area 2%–8%, dan rasio aspek 0,3–3,3;
9. Mixup dengan parameter alfa 0,2 dan probabilitas 0,5 [15]; serta
10. CutMix dengan parameter alfa 1,0 sebagai variasi tambahan pada *batch* pelatihan [16].

Augmentasi pelatihan hanya diterapkan pada data pelatihan dan tidak diterapkan pada data validasi maupun pada evaluasi standar data pengujian. Data validasi dan pengujian hanya melalui *preprocessing* dasar. Prosedur tersebut berbeda dari *Test-Time Augmentation* (TTA) yang digunakan pada evaluasi akhir. Augmentasi pelatihan digunakan untuk menambah variasi data selama pembelajaran, sedangkan TTA menggabungkan prediksi dari beberapa transformasi terhadap citra pengujian yang sama.

III.7.3 Pemodelan

ResNet-50, DenseNet-121, dan VGG16 digunakan sebagai *backbone* dengan bobot pralatih ImageNet. Pada awal setiap *run*, sebagian besar bobot *backbone* dibekukan dan hanya bagian akhir dari setiap arsitektur yang diperbarui melalui proses *fine-tuning*. Pada ResNet-50, bagian yang disesuaikan adalah *layer4*; pada DenseNet-121 mencakup *denseblock4* dan *norm5*; sedangkan pada VGG16 mencakup blok konvolusi kelima atau lapisan dengan indeks ≥ 24.

CBAM ditempatkan setelah ekstraksi fitur dan menggunakan mekanisme *channel attention* serta *spatial attention*. Representasi fitur yang telah diperkuat kemudian diteruskan menuju dua *classification head*. *Head* pertama menghasilkan prediksi spesies, sedangkan *head* kedua menghasilkan prediksi gejala visual pada daun. Struktur tersebut menerapkan pendekatan *multi-task learning* dengan satu representasi fitur bersama.

III.7.4 Pelatihan Model

Pelatihan model menggunakan Focal Loss dengan gamma 2,0 dan *label smoothing* 0,05 pada kedua tugas klasifikasi. Bobot *loss* ditetapkan sebesar 1,0 untuk tugas gejala visual pada daun dan 0,5 untuk tugas spesies. Pemberian bobot lebih tinggi pada tugas gejala visual dilakukan karena tugas tersebut menjadi fokus utama penelitian, sedangkan klasifikasi spesies berfungsi sebagai tugas pendukung. Bobot 1,0 dan 0,5 tersebut merupakan keputusan desain penelitian dan bukan hasil *hyperparameter tuning*. Ketidakseimbangan kelas ditangani menggunakan *WeightedRandomSampler* gabungan. Setiap sampel memperoleh bobot pengambilan berdasarkan perkalian antara bobot invers frekuensi kelas gejala visual dan bobot invers frekuensi kelas spesies. Dengan pendekatan tersebut, sampel dari kombinasi kelas yang relatif jarang memperoleh peluang pengambilan lebih besar selama pembentukan *batch*.

Jumlah sampel yang digunakan dalam satu *epoch* disesuaikan dengan hasil perkalian jumlah kelas gejala visual dan jumlah sampel pada kelas gejala visual terbesar, yaitu 3.350 sampel. Jumlah tersebut lebih besar daripada jumlah citra unik dalam data pelatihan yang berjumlah 1.551 citra karena proses *sampling* memungkinkan suatu citra terambil lebih dari satu kali dalam satu *epoch*. Optimasi dilakukan menggunakan AdamW dengan *differential learning rate*. Bagian *backbone* menggunakan *learning rate* 3×10^{-5}, sedangkan *classification head* menggunakan 2×10^{-3}. Kedua kelompok parameter menggunakan *weight decay* 1×10^{-3}. OneCycleLR digunakan sebagai penjadwal *learning rate* [17], dengan nilai maksimum sebesar lima kali *learning rate* awal untuk *backbone* dan dua kali untuk *classification head*. Parameter *pct_start* ditetapkan sebesar 0,2, sedangkan *div_factor* dan *final_div_factor* masing-masing bernilai 10 dan 1.000.

Pelatihan dilakukan selama maksimal 50 *epoch* dengan *early stopping* setelah 15 *epoch* tanpa peningkatan skor gabungan pada data validasi. Setiap arsitektur dilatih sebanyak lima *run* menggunakan *random seed* berbeda. *Seed* ditentukan menggunakan rumus 42 ditambah ID *run*, sehingga digunakan *seed* 43, 44, 45, 46, dan 47. *Seed* tersebut memengaruhi inisialisasi *classification head* serta proses pengambilan sampel melalui *WeightedRandomSampler*. Pembagian dataset tetap menggunakan *seed* 42 sehingga subset pelatihan, validasi, dan pengujian sama pada seluruh *run*. *Checkpoint* terbaik pada setiap *run* ditentukan berdasarkan *combined score* pada data validasi. Skor tersebut dihitung menggunakan Persamaan III.1.

$$\text{Skor Gabungan} = 0{,}7 \times F1\text{-Macro}_{\text{gejala}} + 0{,}3 \times F1\text{-Macro}_{\text{spesies}}. \qquad \text{(III.1)}$$

Keterangan:

Skor Gabungan = nilai yang digunakan untuk menentukan *checkpoint* dan *run* terbaik pada data validasi;
0,7 = bobot kontribusi tugas klasifikasi gejala visual pada daun;
$F1\text{-Macro}_{\text{gejala}}$ = rata-rata nilai F1-score dari seluruh kelas gejala visual pada daun;
0,3 = bobot kontribusi tugas klasifikasi spesies;
$F1\text{-Macro}_{\text{spesies}}$ = rata-rata nilai F1-score dari seluruh kelas spesies *Hoya*.

Bobot 0,7 untuk gejala dan 0,3 untuk spesies ditetapkan berdasarkan prioritas penelitian. Klasifikasi gejala menjadi fokus utama, sedangkan klasifikasi spesies menjadi tugas pendukung. Bobot tersebut merupakan keputusan desain penelitian dan bukan hasil optimasi hiperparameter. Kriteria yang sama digunakan untuk menentukan *checkpoint* terbaik selama pelatihan dan memilih *run* terbaik dari lima *run* pada setiap arsitektur. Pemilihan model berdasarkan data validasi dilakukan agar data pengujian tetap terpisah dari proses pemilihan model sehingga data pengujian dapat digunakan secara independen untuk mengukur kinerja akhir model [26].

Test-Time Augmentation (TTA) diterapkan pada evaluasi akhir menggunakan data pengujian. Prediksi akhir diperoleh dengan merata-ratakan probabilitas keluaran model dari lima versi citra, yaitu citra asli, *horizontal flip*, *vertical flip*, rotasi 90°, dan rotasi 270°. Prosedur TTA diterapkan secara identik pada ResNet-50, DenseNet-121, dan VGG16 sehingga metode tersebut tidak menjadi sumber perbedaan perlakuan

antararsitektur. Seluruh citra TTA terlebih dahulu melalui *preprocessing* standar sebagaimana dijelaskan pada Subbab III.7.1.

III.7.5 Evaluasi Model

Kinerja klasifikasi spesies dan gejala visual pada daun dievaluasi menggunakan *accuracy*, *precision*, *recall*, F1-score, dan F1-Macro. F1-Macro digunakan untuk memberikan bobot yang sama kepada setiap kelas sehingga kelas dengan jumlah data lebih sedikit tetap memperoleh kontribusi yang setara dalam evaluasi. Setiap arsitektur dilatih sebanyak lima *run* dengan *seed* berbeda. *Run* dengan skor gabungan validasi tertinggi ditetapkan sebagai *run* terbaik untuk arsitektur tersebut. *Checkpoint* dari *run* terbaik kemudian digunakan dalam analisis pada Bab IV, termasuk *classification report*, *confusion matrix*, dan Grad-CAM. Ketiga arsitektur dibandingkan menggunakan metrik dan prosedur evaluasi yang sama.

III.7.6 Analisis Kesalahan Klasifikasi

Analisis kesalahan dilakukan menggunakan *confusion matrix* untuk mengetahui distribusi prediksi benar dan salah pada setiap kelas. Analisis tersebut digunakan untuk mengidentifikasi pasangan kelas yang paling sering tertukar oleh model. Evaluasi kesalahan dilakukan secara terpisah pada klasifikasi 10 spesies dan lima kelas gejala visual pada daun.

III.7.7 Analisis Interpretabilitas Model

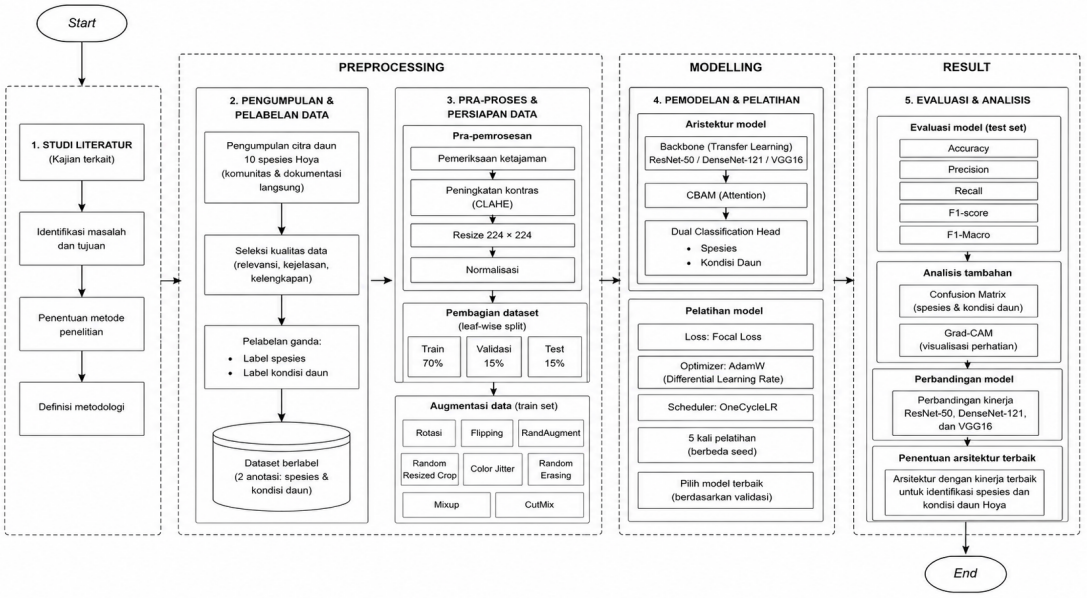
Grad-CAM digunakan untuk mengidentifikasi bagian citra yang memberikan kontribusi terhadap prediksi model. Visualisasi dilakukan pada sejumlah sampel dari data pengujian yang dipilih secara berurutan dari *batch* pertama, dengan jumlah maksimal enam sampel untuk setiap arsitektur.

Hasil visualisasi bersifat ilustratif dan tidak dimaksudkan untuk merepresentasikan keseluruhan pola perhatian model pada seluruh data pengujian. Visualisasi tersebut digunakan untuk mengamati apakah model memberikan perhatian pada bagian daun yang relevan dengan spesies atau gejala yang diprediksi serta menjadi informasi pendukung terhadap hasil evaluasi numerik.

III.8 Tahapan Penelitian

Penelitian diawali dengan studi literatur untuk memperoleh landasan mengenai tanaman *Hoya*, karakteristik spesies, gejala pada daun, pengolahan citra, CNN, *transfer learning*, serta arsitektur ResNet-50, DenseNet-121, dan VGG16. Studi literatur juga digunakan sebagai dasar dalam menentukan metode *preprocessing*, strategi pelatihan, metrik evaluasi, dan teknik interpretabilitas.

Tahap berikutnya adalah pengumpulan citra daun dari 10 spesies *Hoya* melalui dokumentasi langsung dan berbagai sumber daring. Citra yang diperoleh kemudian diperiksa berdasarkan kualitas visual, keberadaan objek daun, dan kesesuaian spesies. Citra yang memenuhi kriteria diberi label berdasarkan spesies *Hoya* dan kategori gejala visual pada daun.



Gambar III.3: Diagram alir tahapan penelitian

Gambar III.3 menggambarkan keseluruhan *pipeline* penelitian yang mencakup pengumpulan dan pelabelan data, *preprocessing* citra, pembagian dataset berdasarkan *leaf ID*, augmentasi data pelatihan, penerapan *WeightedRandomSampler* gabungan, pembangunan model *multi-task learning* dengan CBAM, pelatihan menggunakan Focal Loss dan pembobotan antartugas, pemilihan *checkpoint* dan *run* terbaik berdasarkan skor gabungan validasi, evaluasi akhir menggunakan TTA, serta analisis hasil melalui *confusion matrix* dan Grad-CAM. Seluruh komponen pada diagram disusun sesuai dengan tahapan metodologi yang telah dijelaskan pada bagian III.7. Citra yang telah melalui proses pelabelan selanjutnya diproses agar memiliki format dan karakteristik masukan yang sesuai dengan model. Tahapan *preprocessing* dilakukan berdasarkan prosedur pada bagian III.7.1. Dataset kemudian dibagi menjadi data pelatihan, validasi, dan pengujian dengan rasio 70%:15%:15% berdasarkan *leaf ID* sebagaimana dijelaskan pada bagian III.4.3.

Augmentasi diterapkan pada data pelatihan untuk meningkatkan variasi karakteristik visual dan membantu model membentuk representasi fitur yang lebih *robust*. Tahapan augmentasi mengikuti konfigurasi yang telah ditetapkan pada bagian III.7.2. Data pelatihan selanjutnya digunakan dalam proses pembentukan *batch* melalui *WeightedRandomSampler* sebelum masuk ke model *multi-task learning*. Model dilatih menggunakan tiga arsitektur *backbone*, yaitu ResNet-50, DenseNet-121, dan VGG16, dengan konfigurasi eksperimen yang sama. Setelah proses pelatihan selesai, *checkpoint* terbaik pada setiap *run* ditentukan berdasarkan skor gabungan pada data validasi. Setiap arsitektur menjalani lima *run* dengan *seed* berbeda, kemudian *run* terbaik dipilih menggunakan kriteria skor gabungan validasi yang sama. Evaluasi akhir dilakukan menggunakan data pengujian secara independen dengan penerapan TTA. Hasil evaluasi dianalisis menggunakan metrik klasifikasi, *confusion matrix*, serta Grad-CAM untuk memperoleh gambaran mengenai kinerja dan pola perhatian model.